


Redes neuronales como aproximadores numéricos

*para pricing de opciones bajo
Black-Scholes y Heston*



Autores

Ángel Fernández Sánchez
Jorge Alfageme Sotillos
Héctor Pérez Ledesma

Resumen

Este trabajo estudia bajo qué condiciones una red neuronal profunda puede actuar como un surrogate preciso, rápido y diferenciable de una función de pricing de opciones, entendida como sustituto numérico de un solver matemático ya conocido. El objetivo es abaratar la evaluación de modelos cuya solución analítica no existe o es cara, una vez entrenada offline a partir de datos sintéticos generados por el propio solver, la red puede sustituir al modelo original en tareas que exigen millones de evaluaciones, como la calibración diaria, el cálculo de Greeks o la simulación por Montecarlo. Nuestro objeto de estudio son las opciones europeas vainilla bajo dos modelos: Black-Scholes como caso de validación con solución cerrada y Heston como caso principal, donde la integración por Fourier semi-cerrada es lo suficientemente costosa como para justificar el surrogate. El trabajo se articula en torno a seis experimentos que tienen como objetivo evaluar la eficiencia de los surrogates desde distintas perspectivas del problema; métrica de evaluación, activación de la red, distribución del muestreo, eficiencia computacional, uso de información diferencial en la pérdida y profundidad de la red junto al scheduler de learning rate. Cada uno de los experimentos realizados conduce a diferentes conclusiones muy valiosas sobre las mejoras de eficiencia y las diferentes técnicas que hacen de los surrogates una opción muy atractiva para la industria financiera.

Palabras clave. deep surrogates, pricing de opciones, Heston, Black-Scholes, differential machine learning, métodos numéricos.

Índice general

1. Introducción	2
2. Revisión bibliográfica	3
2.1. Hutchinson, Lo y Poggio (1994): el punto de partida histórico	3
2.2. Becker, Cheridito y Jentzen (2019): deep optimal stopping	4
2.3. Ruf y Wang (2020): mapa del campo	4
2.4. Chen, Didisheim y Scheidegger (2025): deep surrogates en finanzas	5
2.5. Huge y Savine (2020): differential machine learning	6
2.6. Otras líneas complementarias	7
3. Metodología	8
3.1. Casos de estudio: Black-Scholes y Heston	8
3.2. Pipeline experimental	9
3.3. Targets, normalización y métricas	10
3.4. Dominio, muestreo y particiones	11
4. Experimentos	15
5. Resultados	17
5.1. E1 — Precio frente a volatilidad implícita	17
5.2. E2 — Activaciones y calidad de Delta	21
5.3. E3 — Muestreo uniforme frente a enfocado	22
5.4. E4 — Eficiencia computacional	24
5.5. E5 — Differential ML con Delta	26
5.6. E6 — Profundidad de la red y scheduler de learning rate	27
6. Discusión y trabajo futuro	28

1 Introducción

El objetivo general de este trabajo es estudiar cómo se pueden usar las redes neuronales como herramienta numérica para aproximar modelos de pricing de opciones. Es decir, no nos interesa la red como un sistema que aprende del mercado, sino como un aproximador funcional capaz de imitar a un solver matemático ya conocido. La distinción puede parecer sutil pero es fundamental para comprender el valor que aporta este enfoque, la idea es sustituir un cálculo costoso por una aproximación rápida y diferenciable.

En finanzas cuantitativas hay muchos modelos de pricing de opciones, desde el clásico Black-Scholes hasta modelos modernos con volatilidad estocástica, saltos o memoria. Todos ellos tienen una estructura común, dado un conjunto de inputs, que pueden ser características del contrato y parámetros del modelo, devuelven un precio o una volatilidad implícita. El problema es que conforme los modelos ganan realismo también se vuelven más caros de evaluar computacionalmente. Lo que en Black-Scholes es una fórmula cerrada se convierte en Heston en una integral que hay que resolver por Fourier y en Bates o en rough volatility en algo aún más costoso. Cuando estos modelos hay que evaluarlos miles o millones de veces, por ejemplo en calibración diaria, en cálculo de Greeks o en simulación de Montecarlo, el coste se vuelve un cuello de botella real.

La idea de los deep surrogates es resolver ese cuello de botella entrenando una red neuronal a partir de datos sintéticos generados por el propio modelo, de forma que la red aprenda la función de pricing. Si llamamos $f : \mathcal{X} \subset \mathbb{R}^d \rightarrow \mathbb{R}$ a la función de pricing del modelo verdadero, lo que hacemos es entrenar una red $\hat{f}_\theta$ con parámetros θ para que

$$\hat{f}_\theta(x) \approx f(x), \quad x \in \mathcal{X}. \quad (1)$$

Una vez entrenada, evaluarla es órdenes de magnitud más rápido que llamar al solver original. El esquema general se ilustra en la Figura 1.




Figura 1: Esquema general de un deep surrogate: el modelo financiero genera datos sintéticos sobre los que se entrena una red que después sustituye al solver original en evaluaciones masivas.

La red no reemplaza la teoría financiera, simplemente aprende a imitar el solver. El objetivo no es aplicar las técnicas de deep learning a datos de mercado ruidosos, sino utilizar estas técnicas para resolver un problema clásico de aproximación numérica con la ventaja añadida de que el resultado es diferenciable por construcción.

Para Black-Scholes la fórmula cerrada ya es muy rápida y un surrogate no aporta valor práctico, sin embargo, es ideal como caso de validación, porque conocemos la solución exacta y podemos medir errores de precio, Delta y volatilidad implícita con precisión. El objetivo de este trabajo es verificar si se pueden utilizar surrogates con modelos más complejos sin perder precisión, y para ello utilizamos Black-Scholes como baseline y Heston como caso principal de estudio. La pregunta de investigación que estructura todo el trabajo es la siguiente:

¿Bajo qué condiciones una red neuronal profunda puede actuar como un surrogate preciso, rápido y diferenciable para funciones de pricing de opciones?

Para responder esta pregunta en la práctica, hemos decidido segmentar el estudio en seis preguntas más concretas que se traducen en seis experimentos. Cada uno de estos experimentos ataca una perspectiva distinta de la pregunta. No solo nos interesa estudiar si un surrogate es preciso a la hora de imitar el modelo original, sino también estudiar bajo qué condiciones se puede expresar la eficiencia y precisión de esta herramienta.

El documento se organiza de la siguiente manera, la Sección 2 sirve para sintetizar la revisión bibliográfica que ha guiado las decisiones metodológicas del trabajo, es además una sección fundamental para ganar contexto histórico sobre la bibliografía existente y poder afrontar la lectura del trabajo de una forma más contextualizada. La Sección 3 fija los casos de estudio y la metodología experimental. La Sección 4 describe los seis experimentos y las características técnicas de los catorce surrogates que los sostienen. La Sección 5 reporta los resultados de cada experimento. La Sección 6 discute alcance, limitaciones y trabajo en curso.

El código que implementa el pipeline completo: solvers, generación de datos sintéticos, entrenamiento de los surrogates y evaluación por bins, junto con los scripts que reproducen las tablas y figuras de este trabajo está disponible en <https://github.com/hectorperez/proyecto-final-metodos-numericos>.

2 Revisión bibliográfica

La primera fase de nuestro trabajo ha consistido en una investigación bibliográfica profunda para tener una visión global de los temas relevantes y situar nuestra propuesta dentro del panorama existente. Hay cinco artículos que hemos trabajado a fondo y que forman el núcleo de la revisión: los tres primeros eran una recomendación de los profesores como punto de partida, un cuarto, el de deep surrogates, lo encontramos buscando trabajos más recientes en la línea de aproximación numérica de modelos de pricing, y un quinto, el de differential machine learning de Hugué y Savine, que incorporamos como complemento al anterior porque aporta una técnica, que hemos utilizado como inspiración para diseñar el último experimento.

2.1 Hutchinson, Lo y Poggio (1994): el punto de partida histórico

El punto de partida histórico es el trabajo de Hutchinson, Lo y Poggio [1]. Estos autores proponen un método no paramétrico para estimar la fórmula de pricing de un derivado mediante learning networks, en una época en la que la literatura financiera estaba dominada por enfoques paramétricos basados en Black-Scholes y argumentos de no arbitraje. La idea central es invertir la lógica habitual: en lugar de partir de un modelo estocástico para el subyacente y derivar analíticamente la fórmula del precio, dejan que la red aprenda directamente la función que mapea variables económicas observables, como el precio del subyacente normalizado por el strike y el tiempo a vencimiento, al precio de la opción, sin imponer supuestos de lognormalidad ni continuidad de trayectoria. Comparan cuatro arquitecturas, redes de funciones de base radial, perceptrones multicapa, projection pursuit regression y mínimos cuadrados ordinarios como baseline, y atacan a la vez los problemas de pricing y delta-hedging, lo cual es importante porque la cobertura exige que la red aproxime bien no solo el precio sino también su derivada respecto al subyacente. Validan primero con datos sintéticos generados por Monte Carlo bajo Black-Scholes y después con datos reales de opciones sobre futuros del S&P 500 entre 1987 y 1991, donde la red llega a superar a Black-Scholes en tracking error de la cartera replicante.

Su relevancia histórica reside en que es el primer trabajo que demuestra de forma sistemática que una red neuronal puede aprender una fórmula de pricing y usarse operativamente para cubrir, abriendo la línea de investigación que conecta con el enfoque actual de deep surrogates. La diferencia crucial con nuestro proyecto es que aquí la red aprende del mercado, mientras que un surrogate moderno aprende la salida de un pricer ya conocido para acelerarlo: la red pasa de competir con Black-Scholes a aproximarlos de manera eficiente.

2.2 Becker, Cheridito y Jentzen (2019): deep optimal stopping

El segundo paper es el de Becker, Cheridito y Jentzen sobre deep optimal stopping [2]. Aquí los autores proponen un método de deep learning para resolver problemas de parada óptima en tiempo discreto, es decir, problemas en los que hay que decidir en cada instante si parar o continuar un proceso de Markov para maximizar la esperanza de un pago. La idea central es que cualquier tiempo de parada admisible se puede descomponer en una sucesión de decisiones binarias, una por cada paso temporal, y que cada una de esas decisiones puede aprenderse como una función del estado actual mediante una red neuronal feedforward. Sustituyen la indicadora dura por una sigmoide, lo que permite entrenar los parámetros con ascenso de gradiente estocástico sobre trayectorias Monte Carlo, y proceden por inducción hacia atrás desde el último instante hasta el primero. El método se aplica al pricing de opciones bermudas tipo max-call sobre cestas de hasta quinientos activos en un Black-Scholes multidimensional, a un callable multi barrier reverse convertible y al problema no markoviano de parar óptimamente un movimiento browniano fraccionario, con precisión alta y tiempos cortos en dimensiones donde los métodos tradicionales sufren la maldición de la dimensionalidad.

Para nuestra revisión es importante porque ilustra una línea claramente distinta de la nuestra: ellos aprenden directamente la política de ejercicio para derivados con derecho de parada anticipada, mientras que en nuestro proyecto la red actuará como surrogate de la función de pricing de opciones europeas. Son enfoques complementarios dentro del uso del deep learning en finanzas cuantitativas, pero no resuelven el mismo problema, y conviene tener esa distinción clara para evitar comparaciones que no aplican.

2.3 Ruf y Wang (2020): mapa del campo

El tercer paper recomendado es la revisión bibliográfica de Ruf y Wang [3], que funciona como mapa general del campo. Los autores compilan y comparan más de ciento cincuenta artículos en una tabla detallada que cataloga cada estudio según seis dimensiones, entre ellas las variables de entrada, las salidas de la red, los modelos benchmark, las métricas de rendimiento, el método de partición de los datos y los activos subyacentes. Cubren tanto el enfoque puramente no paramétrico, donde la red aprende directamente el precio a partir de variables como subyacente, strike, vencimiento y volatilidad, como los enfoques híbridos que combinan fórmulas paramétricas tipo Black-Scholes con correcciones aprendidas, además de variantes más recientes orientadas a calibración, resolución de PDEs, aproximación de funciones de valor en problemas de control óptimo y deep hedging.

Lo más útil de este paper son las lecciones que extrae del repaso exhaustivo, la importancia de usar inputs estacionarios como la moneyness en lugar de precio y strike por separado y sobre todo, el problema del data leakage que aparece cuando la partición train/test se hace de forma aleatoria sobre datos con estructura temporal, rompiendo el orden cronológico, contaminando el

test e infraestimando sistemáticamente el error de generalización. Para nuestro trabajo es una referencia útil porque ofrece un panorama de la disciplina, permite situar nuestra propuesta dentro de las distintas líneas históricas y nos advierte de errores típicos que conviene evitar, aunque la mayor parte de la bibliografía que analiza versa sobre el uso de técnicas de machine learning directamente sobre datos de mercado y no sobre el problema de aproximar un solver conocido.

2.4 Chen, Didisheim y Scheidegger (2025): deep surrogates en finanzas

Chen, Didisheim y Scheidegger [4] proponen los deep surrogates como una clase de aproximadores numéricos para modelos estructurales costosos, sustituyen la función original por una red neuronal profunda entrenada con muestras simuladas, que toma exactamente los mismos inputs y devuelve la misma salida a un coste computacional drásticamente menor, además de proporcionar gradientes a un coste que no escala con el número de inputs. Aplican la idea al modelo de Bates con saltos doble exponenciales, que tiene cinco variables de estado y ocho parámetros estructurales, resultando en un input de trece dimensiones, y entrenan la red sobre mil millones de observaciones sintéticas para mapear ese input a la volatilidad implícita Black-Scholes asociada.

Una idea crucial del paper es que la maldición de la dimensionalidad queda mitigada por dos factores que se refuerzan entre sí. Por un lado, los datos de entrenamiento se generan de manera sintética y determinista a partir del propio modelo, sin ruido estadístico, lo que elimina la necesidad de cubrir el espacio de inputs con una densidad de muestras que permita promediar errores aleatorios. Por otro lado, la función de pricing en modelos afines como Heston o Bates es analíticamente suave, lo que controla el problema de aproximación y permite a una red profunda representar el mapa de inputs a precio con un número de parámetros que escala de forma manejable con la dimensión. Esta intuición se apoya en resultados teóricos: el trabajo clásico de Barron [11] sobre aproximación de funciones con norma de Barron acotada y, más recientemente, los de Grohs, Hornung, Jentzen y von Wurstemberger [12] demuestran formalmente cómo las redes neuronales profundas escapan a la maldición de la dimensionalidad en la aproximación de soluciones de la ecuación de Black-Scholes en alta dimensión. Juntas, estas dos propiedades justifican que un deep surrogate sea una herramienta de aproximación numérica plausible en problemas de dimensión moderada-alta.

El paper también argumenta de forma explícita por qué las redes neuronales son la familia de aproximadores adecuada frente a alternativas naturales como polinomios globales, splines, sparse grids o Gaussian processes. Los polinomios funcionan razonablemente en funciones suaves pero les cuesta capturar rasgos locales fuertes como kinks, y eso en opciones es un problema serio porque el payoff tiene un kink claro en el strike, con oscilaciones de Runge si se intenta una aproximación global. Los splines capturan bien rasgos locales por tramos pero escalan muy mal en alta dimensión. Las sparse grids mitigan parte del problema de las mallas cartesianas pero rinden peor en dominios irregulares, frecuentes en finanzas por las restricciones entre parámetros. Los Gaussian processes son elegantes pero su coste matricial $O(n^3)$ los hace inviables con millones de observaciones. Las redes neuronales son las únicas que cumplen los cuatro criterios de forma razonable, como resume la Tabla 1.

A esta capacidad de aproximación se añade una ventaja decisiva en el contexto de los métodos numéricos, el jacobiano de la red está disponible a un coste muy reducido mediante diferenciación automática. Esto es crítico en finanzas porque muchas magnitudes que importan no son el precio en sí sino sus derivadas, las griegas, que en el modelo original suelen calcularse por diferencias finitas a un coste considerable para modelos complejos. Chen et al. documentan que la calibración

Método	Alta dimensión	No linealidades	Dominio irregular	Escala n
Polinomios globales	—	—	~	+
Splines	—	+	~	~
Sparse grids	~	+	—	~
Gaussian processes	+	+	+	—
Redes neuronales	+	+	+	+

Tabla 1: Comparación cualitativa de aproximadores numéricos en los cuatro criterios relevantes para surrogates de pricing, en línea con el argumento de Chen et al. Las redes neuronales son las únicas que cumplen los cuatro de forma razonable.

diaria del modelo de Bates pasa de las aproximadamente 125 horas que requiere la inversión FFT a poco más de dos horas en CPU y unas decenas de minutos en GPU cuando se usa el surrogate, una reducción de órdenes de magnitud que abre la puerta a aplicaciones empíricas hasta entonces inviables.

De este paper hemos extraído cuatro lecciones técnicas que han servido para formular nuestros experimentos y orientar las diferentes decisiones arquitectónicas que hemos tomado a lo largo del trabajo. Primero, usar una activación suave (Swish) en lugar de ReLU. ReLU produce errores de precio comparables pero Deltas sustancialmente peores porque su derivada es discontinua en cero, mientras que las activaciones suaves dan derivadas más estables, esta observación motiva directamente nuestro experimento E2. Segundo, evaluar en volatilidad implícita Black-Scholes en vez de en precio, porque IV es la unidad común que pone todas las opciones en una escala homogénea sin importar moneyness ni vencimiento, nosotros mantenemos el precio como target de entrenamiento pero evaluamos en ambas escalas. Tercero, definir un hipercubo amplio y muestrear puntos aleatorios dentro de él; este esquema es la base de nuestro método de generación de datos y el experimento 3 explora la comparación de muestreos uniformes contra muestreos enfocados. Por último, la cuarta lección que extraemos de este paper es prescindir de la regularización clásica del machine learning (sin early stopping, sin dropout, sin weight decay) porque los datos son sintéticos y deterministas, por tanto el ruido en los datos no es un factor a tener en cuenta durante el proceso de entrenamiento.

2.5 Huge y Savine (2020): differential machine learning

El quinto paper es el de Huge y Savine sobre differential machine learning [5]. Este paper ha sido crucial para plantear el experimento 5. La idea es que cuando se entrena un surrogate con datos sintéticos, normalmente la red solo ve el valor de la función en cada punto, por ejemplo el precio de la opción y aprende a predecirlo. Sin embargo, si el modelo verdadero es diferenciable, también se conoce la pendiente de la función en cada punto. Differential machine learning aprovecha esa información añadiendo los gradientes verdaderos al conjunto de entrenamiento y modificando la pérdida para que la red no solo estime el precio, sino también su derivada respecto a los inputs. El resultado es que se consiguen aproximaciones mucho más precisas con datasets sustancialmente más pequeños.

Para nuestro trabajo es una referencia clave ya que tiene una motivación matemática sólida desde el punto de vista de aproximación de funciones, análoga a la que justifica la interpolación de Hermite frente a la clásica, disponer del valor y de la derivada de una función en cada punto muestreado permite reconstruirla con muchos menos puntos. La Figura 2 ilustra esta intuición.




Figura 2: Motivación matemática del differential machine learning: añadir información sobre la derivada en cada nodo permite reconstruir la función con muchos menos puntos. Los segmentos naranja representan las pendientes conocidas.

Aunque nuestro trabajo no adopta esquemas cíclicos ni reinicios cálidos como política general de entrenamiento, sí incorporamos en el experimento E6 una variante con scheduler para estudiar si una adaptación sencilla del learning rate mejora el surrogate baseline. Esta decisión está motivada por la literatura de optimización, donde Smith [13] muestra que variar el learning rate durante el entrenamiento puede mejorar la precisión y reducir el número de iteraciones necesarias frente a una tasa constante, y Loshchilov y Hutter [14] documentan que los schedules con reinicios también mejoran el rendimiento durante el entrenamiento. En nuestro caso no se pretende reproducir exactamente esos esquemas, sino contrastar si una política adaptativa más simple, `ReduceLROnPlateau`, aporta una mejora marginal una vez fijados arquitectura, pérdida y dataset.

2.6 Otras líneas complementarias

Más allá de estos cinco pilares, hemos revisado otros trabajos que ayudan a entender que la aplicación de redes neuronales a derivados ha avanzado en varias direcciones complementarias. Una primera línea ataca de frente el problema de resolver las ecuaciones diferenciales parciales que aparecen en el pricing de derivados de alta dimensión, donde los métodos de mallado tradicionales chocan con la maldición de la dimensionalidad: en esa familia se inscribe el *Deep Galerkin Method* de Sirignano y Spiliopoulos [6], que entrena una red profunda para satisfacer el operador diferencial sobre puntos muestreados al azar y prescinde por completo de la malla, así como el *Deep BSDE Solver* de Han, Jentzen y E [7], que reformula la PDE como una ecuación diferencial estocástica retrógrada y aproxima el gradiente de la solución mediante redes neuronales, demostrando viabilidad incluso en problemas de cien dimensiones.

Una segunda línea busca acelerar la valoración aprendiendo directamente la función de precios, y aquí el trabajo de Ferguson y Green [8] muestra que una red profunda entrenada con datos sintéticos generados por Monte Carlo puede valorar opciones basket millones de veces más rápido que el modelo subyacente. Una tercera vertiente aborda la cobertura de carteras como un problema de aprendizaje por refuerzo, como en el deep hedging de Buehler et al. [9], que parametriza la estrategia de cobertura mediante redes neuronales y la optimiza directamente bajo medidas de riesgo convexas, incorporando de forma natural costes de transacción y otras fricciones de mercado sin necesidad de Greeks. La calibración de modelos estocásticos también se ha beneficiado de estas técnicas: trabajos recientes aplican differential ML al modelo de Heston para reducir drásticamente el tiempo de calibración [10].

De todo este material, el enfoque de surrogates en finanzas es el que mejor encaja con nuestros objetivos. La razón principal es que aborda un problema relevante en la práctica de la industria, abaratar el coste computacional de los modelos de pricing y reducir los tiempos de calibración y estimación de parámetros. Es un problema actual en mesas de derivados y en research cuantitativo, sobre todo a medida que los modelos se vuelven más realistas y por tanto más caros de evaluar. Además, desde el punto de vista de métodos numéricos es el planteamiento más completo porque entrelaza muestreo, aproximación de funciones, validación numérica y cálculo de derivadas en un mismo marco.

3 Metodología

En esta sección se expone cómo se ejecuta cada experimento, qué magnitudes se entrenan y qué métricas se reportan. En un proyecto de surrogates, la parte delicada no es solo entrenar redes, sino asegurar que el dato sintético, la normalización, la métrica y la evaluación responden exactamente a la pregunta que se quiere contestar. La idea central combina dos líneas de la literatura, la lógica de los deep surrogates [4], que entrena una red para aproximar un solver financiero caro a partir de datos sintéticos generados por el propio modelo y la idea del differential machine learning [5], que añade derivadas verdaderas al target de entrenamiento para que la red aprenda también la forma local de la función. En nuestro caso esa derivada será la Delta.

3.1 Casos de estudio: Black-Scholes y Heston

El trabajo se articula sobre dos modelos. El primero es Black-Scholes y opera como caso de validación. En la práctica no necesita un surrogate porque la fórmula cerrada ya es muy rápida, pero precisamente por eso es ideal como entorno de prueba, conocemos la solución exacta, las Deltas analíticas y la inversión a volatilidad implícita, y podemos comparar precio, IV y Greeks contra valores de referencia antes de complicar el problema. El segundo modelo es Heston, donde la motivación del surrogate ya es real, introduce volatilidad estocástica, es bastante más realista y su evaluación requiere integración Fourier semi-cerrada.

Black-Scholes asume que el subyacente sigue un movimiento browniano geométrico bajo la medida de riesgo neutral, con volatilidad σ constante:

$$dS_t = (r - q) S_t dt + \sigma S_t dW_t. \quad (2)$$

El precio de una call europea tiene forma cerrada,

$$C = S e^{-qT} N(d_1) - K e^{-rT} N(d_2), \quad d_{1,2} = \frac{\ln(S/K) + \left(r - q \pm \frac{1}{2}\sigma^2\right) T}{\sigma\sqrt{T}}, \quad (3)$$

con $d_2 = d_1 - \sigma\sqrt{T}$, de donde la Delta es $\Delta = e^{-qT} N(d_1)$. El único parámetro de modelo es la volatilidad σ , que junto con la moneyness $m = S/K$, el vencimiento T y el tipo r forma el espacio de entradas. Esta solución exacta es la que usamos como referencia para validar el pipeline.

Heston añade volatilidad estocástica, la varianza instantánea v_t sigue un proceso de reversión a la media correlacionado con el subyacente,

$$\begin{aligned} dS_t &= (r - q) S_t dt + \sqrt{v_t} S_t dW_t^S, \\ dv_t &= \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^v, \quad dW_t^S dW_t^v = \rho dt, \end{aligned} \quad (4)$$

cuyos parámetros son la velocidad de reversion κ , la varianza a largo plazo θ , la volatilidad de la varianza ξ , la correlación ρ entre los dos brownianos y la varianza inicial v_0 . Estos cinco parámetros, junto con la moneyness $m = S/K$, el vencimiento T y el tipo r , son las entradas que el surrogate aprende a recorrer, de modo que una única red cubre todas las parametrizaciones del modelo. Para este modelo ya no hay fórmula cerrada, el precio se obtiene mediante una representación semi-cerrada de Fourier, lo bastante costosa como para justificar el uso de un surrogate.

3.2 Pipeline experimental

Todos los experimentos de este trabajo siguen la misma dinámica. Primero se define un dominio de inputs y una distribución de muestreo. Después se genera un dataset sintético evaluando el solver verdadero en cada punto. A continuación, se entrena un surrogate con una configuración cerrada y versionada. Finalmente se evalúa el surrogate sobre un conjunto independiente, separando los resultados por bins de moneyness y vencimiento. La separación entre generación, entrenamiento y evaluación es importante porque evita contaminar las conclusiones, el sampler decide dónde preguntamos al modelo verdadero, el solver decide cuáles son los targets, el trainer decide cómo aprende la red y el evaluador decide cómo medimos el error. La Figura 3 esquematiza la arquitectura concreta de la red que usamos y la relación entre el target de precio y la Delta obtenida por autograd.




Figura 3: Arquitectura del surrogate: un MLP de cuatro capas ocultas y 128 unidades con activación Swish que toma como entrada la moneyness, el vencimiento, el tipo y los parámetros del modelo, y produce el precio normalizado $\hat{y} = C/K$. La Delta del surrogate se obtiene derivando $\hat{y}$ respecto a la moneyness por autograd, sin diferencias finitas.

Constantes Experimentales La configuración de la red, el optimizador y el régimen de entrenamiento son comunes a todos los surrogates. Se fijan en código y los valores se recogen en la Tabla 2.

El objetivo global del trabajo no es optimizar la arquitectura de la red o el algoritmo de entrenamiento, el foco está en responder a las diferentes preguntas planteadas sobre las técnicas de muestreo, variables de entrada y métricas de rendimiento. Por este motivo las constantes experimentales que se han fijado no pretenden ser la configuración óptima sino más bien un punto de partida que nos permita comparar de forma limpia los distintos experimentos.

Parámetro	Valor
Arquitectura	MLP, 4 capas ocultas, 128 unidades
Activación por defecto	Swish
Optimizador	Adam, lr = 10^{-3} fijo
Batch size	32 768 (16 384 en variantes small)
Épocas máximas	100
Regularización	ninguna (datos sintéticos)
Moneyiness	$m = S/K$
Normalización de inputs	min-max a $[0, 1]$
Output	precio normalizado C/K
Dividend yield	$q = 0$
Semilla	fijada por configuración

Tabla 2: Constantes comunes a todos los surrogates.

La arquitectura se fija como un MLP de cuatro capas ocultas y 128 unidades por capa. No la presentamos como óptima, sino como una base controlada y suficientemente expresiva para el alcance del trabajo. Mantenerla fija permite que los experimentos midan las decisiones que realmente queremos aislar: activación, distribución de muestreo y pérdida diferencial.

Swish se usa como activación de referencia por su suavidad y por la evidencia del paper de Chen et al., donde se observa que ReLU puede dar errores de precio comparables pero Deltas peores al no ser diferenciable en cero.

El optimizador de referencia es Adam con learning rate fijo. Esta elección no busca optimizar al máximo el entrenamiento, sino mantener una base simple y común a todos los surrogates del catálogo baseline. La única excepción es el experimento E6, donde se introduce de forma controlada una variante con scheduler para medir su efecto aislado sobre el baseline. Fuera de ese caso, mantener el learning rate fijo evita añadir otra decisión de ajuste y facilita atribuir las diferencias observadas a la variable experimental principal.

Las cien épocas se entienden como un presupuesto fijo de entrenamiento, común a todos los modelos. Esta decisión nos ofrece un estándar homogéneo para comparar los surrogates sin introducir reglas de parada distintas entre experimentos. Por último, la semilla se fija por configuración para que cada surrogate sea reproducible y para que las comparaciones dentro de un experimento no dependan de la suerte de la inicialización.

3.3 Targets, normalización y métricas

El target principal de entrenamiento es el precio normalizado por strike, $y = C/K$, y el input financiero principal es la moneyiness simple, $m = S/K$. Esta decisión elimina una escala redundante del problema, si spot y strike se multiplican por la misma constante, el precio de una call europea escala con el strike. Trabajar con C/K y S/K permite que la red aprenda una función más estable y facilita la interpretación de la Delta, porque

$$\Delta = \frac{\partial C}{\partial S} = \frac{\partial(C/K)}{\partial(S/K)} = \frac{\partial y}{\partial m}. \quad (5)$$

También fijamos $q = 0$ en todos los experimentos, el dividend yield no forma parte de las preguntas centrales del trabajo y eliminarlo reduce la dimensión del dominio sin afectar a las comparaciones.

Además de esta normalización financiera, todos los inputs se normalizan numéricamente a $[0, 1]$ antes de entrar en la red. Este ajuste no cambia el problema matemático pero mejora la estabilidad del optimizador porque evita que dimensiones como T , ρ , v_0 o κ vivan en escalas muy distintas. Cuando se calculan derivadas de la red se aplica la regla de la cadena para volver a la escala financiera. En particular, si $m_{\text{norm}} = (m - m_{\text{mín}})/(m_{\text{máx}} - m_{\text{mín}})$, entonces

$$\hat{\Delta} = \frac{\partial \hat{y}}{\partial m} = \frac{1}{m_{\text{máx}} - m_{\text{mín}}} \cdot \frac{\partial \hat{y}}{\partial m_{\text{norm}}}. \quad (6)$$

La Delta del surrogate se calcula con autograd sobre la red, no con diferencias finitas. La Delta verdadera del dataset viene del solver ($N(d_1)$ en Black-Scholes y P_1 en Heston), mientras que la Delta predicha se obtiene derivando $\hat{y}$ respecto a m_{norm} y aplicando la corrección anterior. En evaluación se usa `create_graph=False` porque solo se mide el valor de la derivada y no hace falta retropropagar a través de ella. En el experimento que entrena con pérdida diferencial se usa `create_graph=True` porque la Delta es una derivada, y el término $\text{MAE}(\Delta)$ obliga a derivarla de nuevo respecto a los pesos de la red, lo que constituye una derivada de segundo orden. PyTorch solo puede calcularla si conserva el grafo de la primera pasada hacia atrás, que es justo lo que activa esa opción. Esto incrementa cómputo y memoria por el doble *backward*.

La volatilidad implícita Black-Scholes no será el target principal de entrenamiento, sino una métrica de evaluación. Esta elección mantiene el entrenamiento más directo, porque el solver genera precios, y evita introducir fallos de inversión de volatilidad implícita durante la generación del dataset.

Las métricas de evaluación son tres errores absolutos medios, uno por cada magnitud de interés. Para una magnitud g y un conjunto de puntos de test S , definimos

$$\text{MAE}_g(S) = \frac{1}{|S|} \sum_{x \in S} |\hat{g}(x) - g(x)|, \quad (7)$$

donde $g(x)$ es el valor del solver de referencia y $\hat{g}(x)$ el del surrogate. Las tres magnitudes son el precio normalizado ($g = C/K$), la volatilidad implícita ($g = \sigma_{\text{IV}}$) y la Delta ($g = \Delta$), que dan $\text{MAE}(C/K)$, MAE_{IV} y MAE_{Δ} .

3.4 Dominio, muestreo y particiones

Los datasets de entrenamiento de los surrogates se generan muestreando un hipercubo de inputs. La distribución base es uniforme, porque cubre el dominio completo y no replica únicamente las regiones más frecuentes del mercado. La Tabla 3 fija el dominio contractual común y el dominio adicional de Heston.

La elección de v_0 y θ se expresa en varianza pero se interpreta a través de su raíz cuadrada porque esa es la escala financiera natural. El rango cubre desde volatilidades bajas hasta episodios de estrés severo. No imponemos la condición de Feller $2\kappa\theta \geq \xi^2$ como restricción de muestreo. Tratarla como filtro obligatorio haría el problema más limpio pero menos representativo de calibraciones reales, donde muchas violaciones aparecen en condiciones de mercado normales.

El dominio amplio obliga al solver de Heston a trabajar en esquinas numéricamente exigentes [15], donde la integración de Fourier puede devolver precios con un error diminuto que viola las cotas de no arbitraje de una call europea, el valor intrínseco descontado como suelo y el subyacente como techo. El pipeline lo trata en dos capas. Si la violación es menor que una tolerancia de 10^{-7} , un orden de magnitud por encima del error admitido a la cuadratura, el precio se recorta a

Variable	Rango	Uso
$m = S/K$	[0,4, 2,0]	BS y Heston
T	[7/365, 2,0]	BS y Heston
r	[0,00, 0,075]	BS y Heston
q	0	BS y Heston
σ	[0,03, 1,00]	solo BS
v_0	[0,0009, 1,00]	Heston, $\sqrt{v_0} \in [0,03, 1,00]$
θ	[0,0009, 1,00]	Heston, $\sqrt{\theta} \in [0,03, 1,00]$
κ	[0,10, 10,00]	Heston, reversión lenta a rápida
ξ	[0,10, 3,00]	Heston, vol-of-vol moderada a extrema
ρ	[-0,95, -0,05]	Heston, skew negativo típico de equity

Tabla 3: Dominio contractual común y dominio adicional de Heston. Es deliberadamente amplio e incluye weeklies, wings profundas y volatilidades de estrés.

la cota, que es además el valor al que esas opciones cotizan en la práctica, pues una call muy dentro del dinero vale su intrínseco y una muy fuera del dinero vale cero. Si la violación es mayor, el punto se descarta y se vuelve a muestrear, de modo que cada dataset alcanza exactamente su tamaño nominal solo con datos válidos. El coste del filtro es marginal, en el peor caso se rechaza un 0,15 % de los puntos intentados y la tasa queda registrada en los metadatos de cada dataset. En Black-Scholes, con fórmula cerrada, el rechazo es exactamente cero. El resultado es un dato de entrenamiento libre de arbitraje por construcción.

El muestreo baseline es uniforme en la escala financiera elegida. Formalmente, el dominio de inputs es el hipercubo $\mathcal{D} = \prod_{k=1}^d [l_k, u_k]$, y el sampler uniforme genera cada punto con coordenadas independientes, de densidad

$$p_{\text{unif}}(x) = \prod_{k=1}^d p_k(x_k), \quad x \in \mathcal{D}. \quad (8)$$

Para Black-Scholes cada p_k es uniforme directa sobre m , T , r y σ . Para Heston, κ , ξ y ρ se muestrean también de forma uniforme, pero las varianzas se muestrean en escala de raíz, tomando $\sqrt{v_0} \sim \mathcal{U}[\sqrt{l}, \sqrt{u}]$ —y análogamente θ — y elevando al cuadrado, lo que equivale a una densidad $p_k(x_k) \propto x_k^{-1/2}$ sobre el intervalo. Esta transformación traslada masa hacia las volatilidades bajas y evita que una uniforme directa sobre la varianza sobreponderase las volatilidades extremas.

La comparación de métodos de muestreo se concentra únicamente en el experimento E3. El resto de experimentos usa el baseline uniforme. En E3 se añade un sampler enfocado, con más masa cerca del at-the-money y de vencimientos cortos, donde la función de pricing tiene mayor curvatura. La construcción concreta es una mezcla con peso $\lambda = 1/2$ entre el baseline uniforme y una componente concentrada,

$$p_{\text{foc}}(x) = (1 - \lambda) p_{\text{unif}}(x) + \lambda p_{\text{conc}}(x). \quad (9)$$

La componente concentrada p_{conc} mantiene r y los parámetros de Heston con la misma ley uniforme del baseline, pero reemplaza la moneyness y el vencimiento por una normal truncada centrada en el at-the-money y una log-uniforme en el corto plazo,

$$m \sim \mathcal{N}_{[0,7,1,3]}(1,0, 0,15^2), \quad \log T \sim \mathcal{U}\left[\log \frac{7}{365}, \log 0,25\right]. \quad (10)$$

Así, p_{foc} conserva la cobertura global del dominio a través de su componente uniforme y añade densidad donde la aproximación es más difícil. La Figura 4 compara ambas distribuciones en el plano (m, T) .




Figura 4: Comparación del sampler uniforme (H-3) y del sampler enfocado (H-5). Ambos surrogates se evalúan sobre el mismo test set balanceado para que la comparación E3 mida dónde gana y dónde pierde el enfoque local.

La partición de datos tiene tres niveles. El entrenamiento usa la distribución propia de cada surrogate. La validación usa una muestra independiente uniforme de dos millones y medio de puntos por familia de modelo y sirve para monitorizar convergencia y seleccionar el checkpoint. La regla de selección es siempre el menor $\text{MAE}(C/K)$ en validación, incluso cuando la pérdida de entrenamiento incluye Delta. Mantener la regla fija es importante para que las comparaciones sean limpias. Si el surrogate entrenado con DML se seleccionase con una métrica combinada de precio y Delta, no sabríamos si la mejora viene de la pérdida diferencial o de haber escogido otro punto de la trayectoria de entrenamiento.

Por último, dentro de este apartado metodológico es importante mencionar la técnica de evaluación por bins. Esta técnica es crucial porque el error medio global no es suficientemente representativo, una red puede tener buen MAE agregado y, aun así, fallar sistemáticamente en opciones ATM de vencimiento corto o en regiones OTM donde la Vega es baja. Por eso usamos una partición 5×5 por moneyness y vencimiento, representada en la Figura 5. Formalmente, los intervalos de moneyness $\{M_i\}_{i=1}^5$ y de vencimiento $\{T_j\}_{j=1}^5$ definen veinticinco bins $B_{ij} = M_i \times T_j$, y la métrica de la ecuación (7) se evalúa restringida a cada uno,

$$\text{MAE}_g(B_{ij}) = \frac{1}{|S \cap B_{ij}|} \sum_{x \in S \cap B_{ij}} |\hat{g}(x) - g(x)|. \quad (11)$$




Figura 5: Partición 5×5 del dominio en bins de moneyness y vencimiento. Los bins ATM combinados con weekly, short y medium-short (sombreados en amarillo intenso) son los bins donde se ha concentrado el muestreo en el experimento 3.

Volumen de datos. Los tamaños de entrenamiento y validación de la Tabla 5 corresponden al formato final del proyecto y son consecuencia de una decisión de escalado tomada durante el desarrollo. El diseño inicial era un orden de magnitud menor (200k puntos para Black-Scholes, 500k para Heston, 100k para las variantes small y 50k de validación). Sobre ese diseño todos los surrogates se estancaban en un $\text{MAE}(C/K)$ de validación del orden de 10^{-2} . Tras realizar este primer proceso de generación del dataset y entrenamiento de las redes, pudimos sacar métricas de rendimiento de nuestro hardware disponible (CPU Intel i9-14900K, 64 GB de RAM y GPU NVIDIA RTX 4060), las métricas obtenidas nos permitieron plantear un escalado del dataset de 50 veces el tamaño inicial. Manteniendo fijos arquitectura, optimizador, pérdida, número de épocas y semillas, se redujo el $\text{MAE}(C/K)$ de validación entre un 37 % y un 91 % en los once surrogates pre-registrados, hasta el orden de 10^{-3} . La generación de los datasets costó alrededor de ocho horas de cómputo y reentrenarlos algo más de una hora. Las tres variantes de E6 se entrenaron después sobre este mismo régimen de datos, hasta completar los catorce surrogates del trabajo.

4 Experimentos

El trabajo se estructura a través de 6 experimentos, cada uno responde a una pregunta distinta. Este diseño nos permite hacer una atribución limpia de los cambios observados, si se cambia activación no se cambia dataset, si se cambia sampler no se cambia arquitectura, si se cambia pérdida se conservan tamaño, muestra y parámetros de entrenamiento. Las semillas de generación y entrenamiento quedan fijadas por configuración y registradas para asegurar reproducibilidad.

ID	Pregunta	Lo que varía	Surrogates
E1	¿Un error bajo en precio implica un error bajo en IV?	Métrica de evaluación	BS-3, H-3
E2	¿Qué activación produce mejores Greeks sin degradar el precio?	Activación	BS-1..4, H-1..4
E3	¿El muestreo enfocado reduce el error en bins críticos?	Distribución de muestreo	H-3 vs H-5
E4	¿Qué speedup ofrece el surrogate vs el solver?	Tamaño de lote	H-3
E5	¿Entrenar con Delta diferencial mejora la eficiencia muestral?	Targets de entrenamiento	H-3-small, H-6-small, H-3
E6	¿Aumentar la profundidad de la red o añadir un scheduler de learning rate mejora el baseline?	Profundidad / scheduler	H-3, H-7, H-8, H-9

Tabla 4: Los seis experimentos del trabajo. Cada uno responde a una pregunta única, se altera una única variable y se mantiene todo lo demás fijo.

El experimento 1 es observacional y no requiere entrenar redes adicionales. La idea detrás es sencilla, los surrogates se entrenan con el precio normalizado por moneyness como target, sin embargo, en el día a día de la industria lo habitual es hablar en términos de volatilidad implícita, por ende es muy valioso estudiar cómo se comportan los errores de estimación al invertir las IVs.

El experimento 2 pregunta qué función de activación produce la mejor Delta, esta pregunta tiene el objetivo de ahondar en una idea ya introducida por el paper de DeepSurrogates [4] donde los autores proponen la función Swish como la mejor posicionada para las arquitecturas de los surrogates financieros. Este análisis es muy relevante, ya que no entrenamos la red para predecir la Delta, sino que la obtenemos derivando la propia red por autograd. Como la salida es una composición de capas lineales y activaciones, la suavidad de la activación gobierna directamente la suavidad de esa derivada. En la Figura 6 se aprecia que las cuatro activaciones aproximan el precio con perfiles parecidos, pero solo ReLU tiene una derivada discontinua en cero. Esa discontinuidad se hereda en el gradiente y ensucia la Delta aprendida, mientras que Swish, Softplus y tanh, suaves en todo el dominio, producen derivadas estables. El matiz que da sentido al experimento es que el error en precio puede ser indistinguible entre activaciones, porque todas aproximan bien el valor, y la diferencia solo aflora al mirar la derivada, que es justo la magnitud que importa para cubrir y gestionar riesgo. Por eso la métrica primaria de E2 es el error de Delta y el precio queda como control.




Figura 6: Las cuatro activaciones del experimento E2 y sus derivadas. La derivada de ReLU es discontinua en cero, lo que se propaga a las Deltas calculadas por autograd; las otras tres son suaves en todo el dominio.

El experimento 3 ataca una idea recurrente en métodos numéricos transferida al dominio de los surrogates, concentrar el esfuerzo computacional en las regiones donde la función es más difícil de aproximar. La comparación es limpia porque H-3 y H-5 difieren solo en la distribución de muestreo.

El experimento 4 es de medición, el objetivo es cuantificar la mejora de rendimiento de los surrogates frente a los solvers. Para ello, se cronometran evaluaciones de H-3 contra el solver original de Heston en lotes de tamaño creciente. Reportar la mejora de rendimiento como función del tamaño de lote es más representativo que dar un único número que dependería arbitrariamente del tamaño de lote elegido.

El experimento 5 prueba la hipótesis central del paper de Huge y Savine aplicada a nuestro dominio. Si además de precios generamos la Delta verdadera, ¿puede el surrogate aprender mejor la forma local de la función de pricing con menos datos? La Delta es el target diferencial natural de este experimento. Con $y = C/K$ y $m = S/K$ se cumple $\Delta = \partial y / \partial m$, de modo que es la derivada de la salida respecto a una sola entrada, de primer orden y sin más reescalado que el de la normalización. Además, disponemos de su valor verdadero de forma analítica ($N(d_1)$ en Black-Scholes y P_1 en Heston), lo que da un objetivo fiable contra el que entrenar.

El experimento 6 cierra el estudio explorando dos vías de mejora sobre el baseline H-3 que surgieron del diagnóstico de escalado y que no formaban parte del protocolo inicial. La primera es la profundidad de la red, comparando el baseline de cuatro capas con una variante más superficial (H-7-shallow, dos capas) y otra más profunda (H-8-deep, seis capas). La segunda es un scheduler de learning rate que reduce el paso cuando la validación deja de mejorar (H-9-lr-schedule, con `ReduceLROnPlateau`). Las cuatro variantes comparten dataset, semilla del entrenador, batch, activación y pérdida, de modo que la única variable que cambia es la profundidad o la presencia del scheduler. La lectura es observacional y se ordena por la reducción del error de precio frente al baseline.

Para llevar a cabo los seis experimentos se han entrenado catorce surrogates, recogidos en la Tabla 5. La nomenclatura distingue la familia de modelo, BS para Black-Scholes y H para Heston, y el sufijo small marca las variantes de muestra reducida que usa E5. H-3 en particular es la referencia que atraviesa los seis experimentos, de modo que las comparaciones parten siempre del mismo punto y solo cambia la variable que cada experimento aísla.

ID	Modelo	Activación	Pérdida	Dataset	Experimentos
BS-1	Black-Scholes	ReLU	$L_1(\text{precio})$	10M uniforme	E2
BS-2	Black-Scholes	Softplus	$L_1(\text{precio})$	10M uniforme	E2
BS-3	Black-Scholes	Swish	$L_1(\text{precio})$	10M uniforme	E1, E2
BS-4	Black-Scholes	tanh	$L_1(\text{precio})$	10M uniforme	E2
H-1	Heston	ReLU	$L_1(\text{precio})$	25M uniforme	E2
H-2	Heston	Softplus	$L_1(\text{precio})$	25M uniforme	E2
H-3	Heston	Swish	$L_1(\text{precio})$	25M uniforme	E1–E6
H-4	Heston	tanh	$L_1(\text{precio})$	25M uniforme	E2
H-5	Heston	Swish	$L_1(\text{precio})$	25M enfocado	E3
H-3-small	Heston	Swish	$L_1(\text{precio})$	5M uniforme + Δ	E5
H-6-small	Heston	Swish	$L_1(\text{precio}) + L_1(\Delta)$	5M uniforme + Δ	E5
H-7-shallow	Heston	Swish	$L_1(\text{precio})$	25M uniforme	E6
H-8-deep	Heston	Swish	$L_1(\text{precio})$	25M uniforme	E6
H-9-lr-schedule	Heston	Swish	$L_1(\text{precio})$	25M uniforme	E6

Tabla 5: Los catorce surrogates del trabajo. Todos los comparados dentro de un mismo experimento comparten arquitectura, optimizador, hiperparámetros y protocolo de evaluación; las semillas quedan fijadas por configuración para garantizar reproducibilidad.

5 Resultados

Esta sección presenta los resultados de los seis experimentos, en el mismo orden en que se plantearon en la Sección 4. Cada subsección retoma la pregunta del experimento correspondiente y presenta las métricas observadas a través de gráficos y tablas.

5.1 E1 — Precio frente a volatilidad implícita

En este experimento se utilizan BS-3 y H-3 y se calculan los errores por bin en dos escalas, el precio normalizado C/K y la volatilidad implícita. Comparar ambas responde a la pregunta del experimento, si un error de precio pequeño garantiza también un error de volatilidad implícita pequeño.

La Figura 7 responde a esa pregunta mostrando los errores absolutos medios por bin de las dos métricas, y el contraste entre ellas es el resultado central del experimento. El error de precio $\text{MAE}(C/K)$ es casi uniforme sobre la rejilla, alcanza su máximo en la columna at-the-money de vencimiento corto y su mínimo en las alas, pero todos los bins comparten el mismo orden de magnitud, de modo que un surrogate juzgado solo por el precio parecería homogéneamente bueno en todo el dominio. El error de volatilidad implícita MAE_{IV} se comporta de forma opuesta, es despreciable en el interior y a vencimientos largos, pero crece en las opciones muy fuera y muy dentro del dinero de vencimiento semanal y corto. En consecuencia, las regiones donde la red aproxima mejor el precio son precisamente donde peor recupera la volatilidad implícita, y este patrón se repite sin cambios en Black-Scholes y en Heston.




Figura 7: Errores absolutos medios por bin sobre el test balanceado. Fila superior: BS-3; fila inferior: H-3. Columna izquierda: $MAE(C/K)$ (error de precio); columna derecha: MAE_{IV} (error de volatilidad implícita), esta con escala de color logarítmica porque cruza tres órdenes de magnitud. El error de precio es casi uniforme, con su máximo en ATM de vencimiento corto; el error de IV se concentra en las alas de vencimiento corto. Los dos patrones están anticorrelacionados y se repiten en ambos modelos.

El error se amplifica de forma tan desigual porque pasar de un error de precio a un error de volatilidad implícita no cuesta lo mismo en todo el dominio, depende de cuánto responda el precio a la volatilidad en cada punto. En las regiones donde el precio es muy sensible a la volatilidad, la inversión a IV está bien planteada y un error de precio se traduce en un error de IV parecido. Donde el precio apenas depende de la volatilidad, la inversión está mal condicionada y un error de precio minúsculo se convierte en un error de IV enorme. Esa sensibilidad del precio a la volatilidad es la Vega, de modo que la hipótesis es que la amplificación del error debe crecer justo donde la Vega se desploma.

Para contrastar este análisis con una única magnitud comparable entre Black-Scholes y Heston, se ha introducido una Vega proxy, que se define como la Vega de Black-Scholes evaluada en la volatilidad implícita del precio objetivo. Como la inversión a IV se hace siempre contra Black-Scholes, esa proxy es la pendiente local que gobierna la conversión de precio a IV. En Black-Scholes coincide con la Vega verdadera y en Heston, que no tiene una Vega nativa, actúa

como aproximación comparable. La Tabla 6 cuantifica el contraste sobre H-3 en una selección de bins que cubre todo el espectro de la rejilla, y añade la Vega proxy media del bin y la tasa de fallos de inversión de IV. La razón $\text{MAE}_{\text{IV}}/\text{MAE}(C/K)$ pasa de valores de orden unidad en el interior a más de mil en las alas de vencimiento corto, y esa amplificación acompaña punto por punto al colapso de la Vega proxy y al aumento de los fallos, tal como anticipa la hipótesis.

Bin (H-3)	$\text{MAE}(C/K)$	MAE_{IV}	razón	Vega proxy	fallo IV
Alas y vencimiento corto (Vega baja)					
deep_otm_weekly	$1,1 \times 10^{-3}$	1,57	1444	$7,3 \times 10^{-5}$	41,0 %
deep_otm_short	$6,8 \times 10^{-4}$	$7,8 \times 10^{-1}$	1136	$8,8 \times 10^{-4}$	35,6 %
deep_otm_medium_short	$4,1 \times 10^{-4}$	$1,9 \times 10^{-1}$	465	$9,8 \times 10^{-3}$	26,6 %
deep_itm_weekly	$1,7 \times 10^{-3}$	$5,8 \times 10^{-1}$	345	$1,4 \times 10^{-3}$	55,8 %
Interior y vencimiento largo (Vega alta)					
atm_long	$9,6 \times 10^{-4}$	$2,2 \times 10^{-3}$	2,3	$4,3 \times 10^{-1}$	0,08 %
atm_medium	$7,7 \times 10^{-4}$	$2,8 \times 10^{-3}$	3,7	$2,9 \times 10^{-1}$	0,06 %
otm_medium	$5,9 \times 10^{-4}$	$4,1 \times 10^{-3}$	6,9	$2,0 \times 10^{-1}$	2,8 %

Tabla 6: E1 sobre H-3: bins seleccionados ordenados por razón $\text{MAE}_{\text{IV}}/\text{MAE}(C/K)$. El error de precio es casi constante en todo el dominio, pero el error de IV se amplifica hasta tres órdenes de magnitud en las regiones de Vega baja, donde además fracasa con frecuencia la inversión a volatilidad implícita.

Formalmente, como el precio es monótono en la volatilidad con derivada $\partial C/\partial \sigma = \mathcal{V}$, conocida como Vega, un error de precio δC se traduce a primer orden en un error de volatilidad implícita

$$\delta \sigma \approx \frac{\delta C}{\mathcal{V}}. \quad (12)$$

La amplificación es, por tanto, inversamente proporcional a la Vega del bin, máxima en las opciones muy fuera del dinero o de vencimiento muy corto y de orden unidad en las at-the-money de vencimiento largo. La Figura 8 hace visible esta relación reuniendo en un único plano el error de precio, el error de IV y la Vega de cada bin.




Figura 8: Error de IV frente a error de precio por bin. Cada marcador es uno de los 25 bins del test balanceado, para H-3 (círculos) y BS-3 (triángulos). El eje horizontal es el $MAE(C/K)$ y el vertical el MAE_{IV} , ambos en escala logarítmica. El color codifica la Vega proxy media del bin (barra lateral): tonos oscuros son Vega baja, tonos dorados Vega alta. Las diagonales discontinuas son rectas de razón constante $MAE_{IV}/MAE(C/K)$: un punto sobre la línea $\times 100$ tiene un error de IV cien veces mayor que su error de precio. Los dos bins anotados son los más extremos de cada surrogate.

Cada punto del plano es un bin y su altura relativa a la abscisa mide la amplificación del error, a un mismo error de precio los bins se reparten sobre diagonales de razón muy distintas, desde la identidad hasta más de mil, lo que confirma que el error de precio no determina el error de IV. El color ordena la dispersión, porque los puntos que ascienden hacia las diagonales altas son sistemáticamente los de Vega baja.

La conclusión de E1 es principalmente metodológica. Un $MAE(C/K)$ bajo no implica un MAE_{IV} bajo, porque en las regiones de Vega baja, que son las operativamente delicadas, dos surrogates con error de precio indistinguible pueden diferir por varios órdenes de magnitud en la IV. Esas mismas regiones acumulan un segundo problema, porque ahí la inversión a volatilidad implícita no solo amplifica el error sino que con frecuencia ni siquiera converge, con tasas de fallo que de media por bin alcanzan el 24,1 % en BS-3 y el 14,5 % en H-3. Un fallo de inversión significa que el precio predicho por el surrogate cae fuera del intervalo de no arbitraje, de modo que su volatilidad implícita ni siquiera existe. Ocurre precisamente donde el precio verdadero está pegado a la cota y el error absoluto de la red, aunque pequeño, basta para cruzarla. Son, además, las opciones más ilíquidas, donde el propio mercado cotiza la volatilidad implícita con menos fiabilidad, de modo que el surrogate falla justo donde el dato de referencia también es más frágil.

5.2 E2 — Activaciones y calidad de Delta

Este segundo experimento compara las cuatro activaciones más comunes (ReLU, Softplus, Swish y tanh) sobre Black-Scholes y sobre Heston, manteniendo arquitectura, optimizador y dataset fijos. La métrica primaria es MAE_{Δ} por bin; $MAE(C/K)$ se reporta como control para verificar que las activaciones suaves no degradan el nivel del precio. La hipótesis es que la falta de suavidad de ReLU se propaga a la Delta calculada por autograd, generando errores sustancialmente mayores aunque el precio sea comparable.

La pregunta tras este experimento tiene dos caras que conviene mirar simultáneamente, porque una determinada función de activación solo es preferible si mejora la Delta sin renunciar a precisión en precio, una Delta más limpia obtenida a costa de un precio peor no tendría ningún valor. Por eso, la Figura 9 sitúa cada activación en el plano cuyos ejes son el error de precio y el error de Delta, promediados sobre los 25 bins, donde la esquina inferior izquierda corresponde a poco error en ambas métricas y un desplazamiento hacia la derecha o hacia arriba señala el coste pagado en una de ellas.




Figura 9: Compromiso entre error de precio y error de Delta por activación, para Black-Scholes (izquierda) y Heston (derecha). Cada punto es una activación, promediando el error sobre los 25 bins del test balanceado; el eje horizontal es el $MAE(C/K)$ y el vertical el MAE_{Δ} . Abajo a la izquierda es mejor en ambas métricas. Los colores coinciden con los de la Figura 6. Swish (verde) ocupa la esquina inferior izquierda en las dos familias.

La lectura del plano es directa. Swish ocupa la esquina inferior izquierda en las dos familias, es decir, consigue a la vez el menor error de Delta y un error de precio igual o inferior al del resto, de modo que su ventaja en la derivada no se logra a costa del precio. ReLU logra un precio muy preciso pero tal y como señala el paper de DeepSurrogates [4], una muy mala Delta, lo que concuerda con su falta de suavidad. La derivada de ReLU es discontinua en cero y esa discontinuidad se propaga a la Delta que se obtiene por autograd. Softplus tiene el mayor error de precio sin mejorar la Delta y tanh queda en una posición intermedia en Black-Scholes pero da la peor Delta en Heston.

La Tabla 7 recoge los números exactos, incluyendo el percentil 95 del peor bin como diagnóstico de cola.

Surrogate	Activación	MAE $_{\Delta}$ media	MAE $_{\Delta}$ p95 (peor bin)	MAE(C/K) media
Black-Scholes				
BS-3	Swish	$1,78 \times 10^{-2}$	$1,87 \times 10^{-1}$	$1,80 \times 10^{-3}$
BS-2	Softplus	$2,32 \times 10^{-2}$	$2,11 \times 10^{-1}$	$4,27 \times 10^{-3}$
BS-4	tanh	$2,59 \times 10^{-2}$	$2,52 \times 10^{-1}$	$2,78 \times 10^{-3}$
BS-1	ReLU	$2,69 \times 10^{-2}$	$1,57 \times 10^{-1}$	$1,97 \times 10^{-3}$
Heston				
H-3	Swish	$1,11 \times 10^{-2}$	$1,76 \times 10^{-1}$	$1,28 \times 10^{-3}$
H-2	Softplus	$1,58 \times 10^{-2}$	$1,82 \times 10^{-1}$	$2,63 \times 10^{-3}$
H-1	ReLU	$1,64 \times 10^{-2}$	$1,22 \times 10^{-1}$	$1,27 \times 10^{-3}$
H-4	tanh	$1,72 \times 10^{-2}$	$2,07 \times 10^{-1}$	$1,91 \times 10^{-3}$

Tabla 7: E2: error medio de Delta y de precio por activación, agregados sobre los 25 bins del test balanceado, más el percentil 95 del peor bin en Delta. Swish minimiza MAE $_{\Delta}$ en ambas familias. El control de precio se mantiene en el mismo orden de magnitud para todas las activaciones.

El error de Delta se concentra en los mismos bins para todas las activaciones, los at-the-money de vencimiento corto, donde la curvatura de la superficie es mayor, de manera que las activaciones difieren en el nivel del error y no en su localización. Un matiz de cola evita sobreinterpretar el resultado, porque ReLU, pese a su peor o casi peor Delta media, tiene el percentil 95 del peor bin más bajo de las cuatro, así que su error es uniformemente mediocre en lugar de catastrófico en regiones concretas. En definitiva, la conclusión de E2 es que, entre las cuatro, Swish es la única elección que mejora las derivadas sin coste apreciable en precio, en línea con la recomendación de Chen et al.

5.3 E3 — Muestreo uniforme frente a enfocado

E3 contrasta H-3 (muestreo uniforme) y H-5 (muestreo enfocado en $m \in [0,7, 1,3]$ y vencimientos cortos) evaluados sobre el mismo test balanceado, manteniendo todo lo demás fijo. La métrica primaria es MAE $_{IV}$ en los bins ATM combinados con weekly, short y medium-short, y como controles reportamos el MAE $_{IV}$ global y el MAE(C/K). El interés está en cuánto reduce el muestreo enfocado el error en esos bins críticos y a qué coste en el resto del dominio.

Como H-3 y H-5 comparten arquitectura, pérdida, tamaño de dataset y test, y difieren únicamente en la distribución de muestreo de la Figura 4, cualquier diferencia en el error es atribuible al muestreo. La Figura 10 lo resume mostrando, bin a bin, la mejora relativa al pasar del muestreo uniforme al enfocado en dos métricas: la volatilidad implícita, que es la métrica primaria del experimento, y el precio, que actúa como control porque no pasa por la inversión a IV y, por tanto, no hereda la amplificación por Vega descrita en E1 mediante la ecuación (12). Para una métrica g y un bin B , el mapa de color representa la mejora relativa

$$\rho_g(B) = \frac{\text{MAE}_g^{\text{H-3}}(B) - \text{MAE}_g^{\text{H-5}}(B)}{\text{MAE}_g^{\text{H-3}}(B)}, \quad (13)$$

positiva cuando el muestreo enfocado reduce el error en ese bin y negativa cuando lo aumenta.




Figura 10: Mejora relativa de H-5 (enfocado) respecto a H-3 (uniforme) por bin, en volatilidad implícita (izquierda) y en precio (derecha), calculada para cada métrica como $(MAE^{H-3} - MAE^{H-5})/MAE^{H-3}$. Los tonos verdes indican que el muestreo enfocado reduce el error y los rojos que lo aumenta. El panel de precio sirve de control porque no está afectado por la amplificación de Vega que introduce la inversión a volatilidad implícita.

Las dos métricas coinciden en lo esencial. La ganancia del muestreo enfocado se concentra en at-the-money y vencimientos cortos, donde el sampler de la Figura 4 traslada la mitad de su masa, con mejoras de hasta el 86 % tanto en IV como en precio, y el coste se localiza en las alas fuera del dinero de vencimiento medio y largo, que el sampler desatiende. La comparación entre paneles aísla además el efecto de la Vega: en el rincón deep OTM de vencimiento largo el deterioro aparente en IV alcanza el 85 %, pero en precio se queda en el 57 %, porque la Vega baja amplifica el error de inversión, de modo que el muestreo enfocado empeora ahí la aproximación pero la métrica de IV lo exagera. En conjunto, H-5 mejora en 19 de los 25 bins en IV y en 16 en precio, con el deterioro confinado en ambos casos a las mismas alas de baja liquidez.

La Tabla 8 cuantifica la métrica primaria, que es el MAE_{IV} medio en los tres bins críticos at-the-money, y los controles globales. La mejora en los bins críticos es del 79,7 %, una reducción muy sustancial del error. El error global tampoco empeora; al contrario, el muestreo enfocado lo reduce en términos generales todos los estadísticos. La media sobre bins está dominada por unas pocas colas de error elevado, las alas de Vega baja donde además la inversión a IV es poco fiable, de modo que por sí sola no es un buen resumen de la calidad global. Por eso, se ha incorporado a la tabla la mediana y el percentil 75, para evitar esas distorsiones provocadas por las colas. En IV la media mejora un 21,2 % y la mediana un 32,2 %. El control de precio, ajeno a la amplificación de Vega, mejora de forma análoga y estable entre estadísticos (media 29,1 %, mediana 26,8 %, p75 34,6 %).

	H-3 (uniforme)	H-5 (enfocado)	mejora
Bins críticos — MAE_{IV}			
atm_weekly	$8,37 \times 10^{-2}$	$1,20 \times 10^{-2}$	+85,7 %
atm_short	$2,30 \times 10^{-2}$	$7,44 \times 10^{-3}$	+67,7 %
atm_medium_short	$8,17 \times 10^{-3}$	$3,91 \times 10^{-3}$	+52,2 %
media	$3,83 \times 10^{-2}$	$7,78 \times 10^{-3}$	+79,7 %
Global — MAE_{IV}			
media	$1,65 \times 10^{-1}$	$1,30 \times 10^{-1}$	+21,2 %
mediana	$2,30 \times 10^{-2}$	$1,56 \times 10^{-2}$	+32,2 %
p75	$9,11 \times 10^{-2}$	$6,08 \times 10^{-2}$	+33,2 %
Global — MAE(<i>C/K</i>)			
media	$1,28 \times 10^{-3}$	$9,11 \times 10^{-4}$	+29,1 %
mediana	$1,08 \times 10^{-3}$	$7,93 \times 10^{-4}$	+26,8 %
p75	$1,61 \times 10^{-3}$	$1,05 \times 10^{-3}$	+34,6 %

Tabla 8: E3: métrica primaria (mejora del MAE_{IV} en los bins críticos at-the-money) y controles globales agregados sobre los 25 bins con tres estadísticos —media, mediana y percentil 75—, sobre el mismo test balanceado. La media es sensible a las colas de error elevado, por lo que se acompaña de mediana y p75, más robustos. La columna de mejora expresa la reducción relativa del error de H-5 frente a H-3; un valor positivo indica que el muestreo enfocado reduce el error.

En conjunto, el muestreo enfocado reduce de forma marcada el error en las regiones de mayor curvatura sin sacrificar la cobertura global, que de hecho también mejora. La interpretación práctica es que concentrar el esfuerzo de muestreo donde la función de pricing es más difícil de aproximar es una técnica eficaz para mejorar la calidad del surrogate en las opciones operativamente más relevantes, a cambio de un deterioro acotado en zonas del dominio de menor interés.

5.4 E4 — Eficiencia computacional

El objetivo de este experimento es cuantificar la mejora de tiempos de la evaluación de H-3 frente al solver semi-cerrado de Heston para lotes de 10^2 , 10^3 , 10^4 y 10^5 opciones. Para medir estas mejoras, se han cronometrado los tiempos de 10 ejecuciones sobre diferentes tamaños de lote y sobre estos resultados se ha reportado el speedup relativo, definido para cada tamaño de lote B como

$$s(B) = \frac{t_{\text{solver}}(B)}{t_{\text{surrogate}}(B)}, \quad (14)$$

donde $t(B)$ es la mediana de los diez tiempos medidos para ese lote. CPU y GPU se reportan por separado para no mezclar mejora algorítmica con diferencia de hardware. El surrogate se evalúa siempre con `model.eval()` y `torch.no_grad()`.

La Figura 11 muestra, a la izquierda, el tiempo mediano de evaluación frente al tamaño de lote en escala doblemente logarítmica, y a la derecha el speedup correspondiente. El solver de Heston escala de forma aproximadamente lineal con el número de opciones, porque valora punto a punto mediante cuadratura adaptativa, mientras que el surrogate procesa el lote completo como una única operación matricial, de modo que su coste por opción disminuye al crecer el lote y amortiza el coste fijo de lanzamiento y de transferencia de datos. Esa diferencia de comportamiento es la que hace que el speedup no sea un número único, sino una función creciente del tamaño de lote.




Figura 11: Eficiencia de H-3 frente al solver semi-cerrado de Heston. Izquierda: tiempo mediano de evaluación por tamaño de lote. Derecha: speedup $t_{\text{solver}}/t_{\text{surrogate}}$. Mediciones en CPU Intel i9-14900K, con el solver paralelizado en 22 procesos, y GPU NVIDIA RTX 4060.

La Tabla 9 recoge las medianas y los speedups por tamaño de lote. El surrogate es entre dos y cuatro órdenes de magnitud más rápido que el solver, y la ventaja crece con el lote: en CPU pasa de un factor 66 con cien opciones a 748 con cien mil, y en GPU de 175 a 6434. La GPU se beneficia más del paralelismo masivo, sobre todo en lotes grandes, mientras que en lotes pequeños su ventaja se reduce porque domina el coste fijo de lanzamiento de núcleos y del intérprete. En términos de throughput, el surrogate en GPU evalúa del orden de doce millones de opciones por segundo a lote 10^5 , frente a las cerca de dos mil por segundo del solver repartido en veintidós núcleos.

Lote	Solver (s)	Surrogate CPU (s)	Surrogate GPU (s)	Speedup CPU	Speedup GPU
10^2	$7,60 \times 10^{-2}$	$1,16 \times 10^{-3}$	$4,35 \times 10^{-4}$	$\times 66$	$\times 175$
10^3	$2,76 \times 10^{-1}$	$3,27 \times 10^{-3}$	$3,76 \times 10^{-4}$	$\times 85$	$\times 735$
10^4	2,37	$6,74 \times 10^{-3}$	$3,97 \times 10^{-3}$	$\times 353$	$\times 599$
10^5	$5,16 \times 10^1$	$6,89 \times 10^{-2}$	$8,02 \times 10^{-3}$	$\times 748$	$\times 6434$

Tabla 9: E4: tiempo mediano de evaluación del solver y del surrogate (CPU y GPU) y speedup por tamaño de lote, sobre diez repeticiones medidas. El solver se mide una sola vez por lote porque no depende del dispositivo del surrogate.

La lectura práctica de E4 es que la ventaja del surrogate se materializa por completo en el régimen de lotes grandes, que es precisamente el de los casos de uso que motivan el enfoque: la calibración diaria, el cálculo masivo de Greeks o la simulación de escenarios requieren del orden de 10^4 a 10^5 evaluaciones, donde el surrogate en GPU reduce el tiempo de decenas de segundos a milisegundos. Para evaluaciones aisladas o lotes pequeños la mejora existe pero es mucho menor, y el coste de entrenar el surrogate no queda justificado.

5.5 E5 — Differential ML con Delta

Este experimento está inspirado en el trabajo de Huge y Savine sobre differential machine learning [5]. E5 compara H-3-small y H-6-small, ambos entrenados sobre las mismas 5M de muestras y con la misma semilla, además en los resultados se ha incluido H-3 (25M muestras) como referencia de muestra grande. Los surrogates de precio minimizan únicamente el error de precio, mientras que el surrogate diferencial añade un término sobre la Delta obtenida por autograd:

$$L_{\text{precio}}(\theta) = \frac{1}{N} \sum_{i=1}^N |\hat{y}_{\theta}(x_i) - y_i|, \quad (15)$$

$$L_{\text{dif}}(\theta) = \frac{1}{N} \sum_{i=1}^N |\hat{y}_{\theta}(x_i) - y_i| + \frac{1}{N} \sum_{i=1}^N |\hat{\Delta}_{\theta}(x_i) - \Delta_i|, \quad (16)$$

donde $\hat{\Delta}_{\theta}$ es la Delta del surrogate calculada por autograd y los dos términos llevan peso unidad. H-3-small y H-3 usan L_{precio} y H-6-small usa L_{dif} , de modo que la única diferencia entre H-3-small y H-6-small es ese segundo término. La métrica primaria es la mejora de MAE_{Δ} de H-6-small sobre H-3-small, con $\text{MAE}(C/K)$ como control para comprobar que la ganancia en la derivada no se paga en precio.

La Figura 12 sitúa los tres surrogates en el plano de error de precio frente a error de Delta, el mismo de E2, promediando sobre los bins. La comparación primaria es entre los dos surrogates de 5M, que comparten dataset y solo difieren en la pérdida. H-6-small, entrenado con el término diferencial, se sitúa claramente por debajo y a la izquierda de H-3-small: mejora la Delta y, lejos de pagarlo en precio, también lo reduce. La segunda lectura es la de eficiencia muestral: H-6-small queda por debajo de H-3 en el eje de Delta pese a haberse entrenado con cinco veces menos datos, aunque a su derecha en precio, donde el mayor volumen de H-3 conserva la ventaja.




Figura 12: Compromiso entre error de precio y error de Delta de los tres surrogates de E5, promediado sobre los 25 bins del test balanceado. Abajo a la izquierda es mejor en ambas métricas. H-3-small y H-6-small comparten datos (5M) y semilla y difieren solo en la pérdida; H-3 es el baseline de muestra grande (25M). El surrogate diferencial H-6-small domina a su par de precio y mejora la Delta del baseline grande con cinco veces menos datos.

La Tabla 10 recoge las cifras agregadas.

Surrogate	Pérdida	Datos	MAE_{Δ}	$MAE(C/K)$
H-3-small	$L_1(\text{precio})$	5M	$1,74 \times 10^{-2}$	$2,54 \times 10^{-3}$
H-6-small	$L_1(\text{precio}) + L_1(\Delta)$	5M	$7,14 \times 10^{-3}$	$1,51 \times 10^{-3}$
H-3	$L_1(\text{precio})$	25M	$1,11 \times 10^{-2}$	$1,28 \times 10^{-3}$

Tabla 10: E5: error medio de Delta y de precio de los tres surrogates, agregados sobre los 25 bins. H-3-small y H-6-small comparten todo salvo la pérdida; H-6-small añade el término $L_1(\Delta)$. H-3 actúa como referencia de muestra grande, entrenado solo en precio sobre cinco veces más datos.

En cifras, el término diferencial reduce el error de Delta de H-6-small frente a H-3-small en un 58,9 %, una mejora muy notable, y el error de precio no solo no empeora sino que mejora un 40,6 %. La mejora es además homogénea, H-6-small supera a H-3-small en Delta en los 25 bins. Frente al baseline grande H-3, H-6-small reduce el error de Delta un 35,8 % usando cinco veces menos datos, ganando en 24 de los 25 bins con la única excepción de deep ITM de vencimiento medio, mientras que en precio H-3 conserva una ventaja del 14,9 %. La lectura conjunta reproduce en nuestro contexto el resultado central de Huge y Savine [5], lo que se traduce en mejores Greeks y en una eficiencia muestral tangible, ya que un surrogate diferencial entrenado con 5M de muestras supera en Delta a uno de precio entrenado con 25M.

5.6 E6 — Profundidad de la red y scheduler de learning rate

La Figura 13 y la Tabla 11 resumen el experimento, comparando las cuatro variantes en error de precio y de Delta promediados sobre los 25 bins del test balanceado. El objetivo de E6 era acotar si dos modificaciones locales sobre el baseline H-3 — cambiar la profundidad de la red o introducir un scheduler de learning rate — podían mejorar el surrogate manteniendo fijo el resto del pipeline.




Figura 13: E6: $MAE(C/K)$ y MAE_{Δ} medios por bin de las cuatro variantes sobre el test balanceado. El baseline H-3 (4×128) se resalta en dorado; H-7-shallow (2×128) y H-8-deep (6×128) cambian la profundidad y H-9-lr-schedule añade un scheduler `ReduceLROnPlateau`.

El resultado principal es que el scheduler es la única modificación que mejora la métrica primaria. H-9-lr-schedule reduce el error medio de precio frente al baseline H-3 en un 10,6 %, pasando

Surrogate	Arquitectura	MAE(C/K)	MAE $_{\Delta}$	Reducción precio
H-9-lr-schedule	$4 \times 128 + \text{plateau}$	$1,15 \times 10^{-3}$	$1,18 \times 10^{-2}$	+10,6 %
H-3 (baseline)	4×128	$1,28 \times 10^{-3}$	$1,11 \times 10^{-2}$	—
H-8-deep	6×128	$2,01 \times 10^{-3}$	$1,17 \times 10^{-2}$	−56,8 %
H-7-shallow	2×128	$3,57 \times 10^{-3}$	$3,03 \times 10^{-2}$	−178,2 %

Tabla 11: E6: error medio de precio y de Delta por bin de las cuatro variantes, y reducción del error de precio frente al baseline H-3. Un valor positivo indica mejora sobre el baseline.

de $1,28 \times 10^{-3}$ a $1,15 \times 10^{-3}$. Ninguna de las dos modificaciones de profundidad consigue una mejora comparable: H-8-deep empeora hasta $2,01 \times 10^{-3}$ y H-7-shallow hasta $3,57 \times 10^{-3}$.

Sin embargo, esa mejora del scheduler no se transfiere al resto de diagnósticos. En Delta, H-9-lr-schedule queda ligeramente por detrás del baseline ($1,18 \times 10^{-2}$ frente a $1,11 \times 10^{-2}$), lo que sugiere que el ajuste fino del learning rate beneficia sobre todo a la aproximación media del precio, pero no mejora la sensibilidad local de la red. La variante profunda H-8-deep presenta un comportamiento intermedio: no mejora al baseline ni en precio ni en Delta, pero queda relativamente cerca de H-3 en ambas métricas. La interpretación natural es que una mayor profundidad no aporta por sí sola una ganancia neta bajo el mismo presupuesto de épocas y con el mismo learning rate fijo.

La variante superficial H-7-shallow es, con diferencia, la peor de las cuatro. Su error medio de precio casi triplica el del baseline y su error de Delta es también claramente superior, lo que apunta a una capacidad insuficiente para aproximar la función de pricing de Heston en el dominio amplio del proyecto.

En conjunto, E6 sugiere que el baseline H-3 ya se encontraba en una región razonable del espacio de arquitecturas. Reducir profundidad perjudica claramente el surrogate, aumentarla no aporta una mejora neta con el mismo régimen de entrenamiento, y la única mejora marginal útil proviene del scheduler, pero solo en la métrica primaria de precio.

6 Discusión y trabajo futuro

Los seis experimentos, leídos en conjunto, dejan una idea clara de cuándo y cómo una red puede sustituir a un solver de pricing. Estos resultados apuntan a usos concretos en la industria. El surrogate no tiene sentido para valorar una opción suelta, donde el solver original ya es rápido, sino para las tareas que exigen millones de evaluaciones, la calibración diaria de un modelo a los precios de mercado, el cálculo de riesgo y de Greeks sobre carteras grandes, o la simulación por Montecarlo.

Conviene tener claras las limitaciones de este trabajo, en primer lugar, parece evidente que falta profundizar más en la optimización de las arquitecturas de los surrogates y parámetros de entrenamiento, ámbitos donde este trabajo no está enfocado. Las conclusiones del proyecto, son comparativas, indican qué decisiones de diseño hacen mejor a un surrogate. También existen limitaciones en lo que respecta a dimensiones de las redes y los datasets sintéticos debido a las restricciones computacionales.

Con estas limitaciones en mente, las líneas de investigación que se abren tienen un interés práctico evidente. Ampliar el entrenamiento diferencial al resto de las Greeks convertiría al surrogate en un motor de riesgo completo, no solo en un aproximador de precios. Extenderlo a opciones

americanas y exóticas lo llevaría justo a los productos donde valorar es genuinamente caro y donde, por tanto, una red rápida aporta más. Probarlo dentro de un proceso de calibración real mediría su utilidad en términos de negocio. Por último, escalar de forma sustancial el tamaño de la red y de los datos serviría para medir hasta dónde puede llegar la precisión de los surrogates.

Para terminar, es interesante reflexionar sobre el potencial de los surrogates desde un punto de vista de métodos numéricos. En términos generales, un surrogate constituye la sustitución de un modelo directo costoso de evaluar por un aproximador entrenado que reproduce su salida a una fracción del coste. Su aplicabilidad no depende del dominio concreto sino de una condición estructural, que el cuello de botella sea la evaluación repetida del solver original, de manera que el coste de generar los datos y entrenar la red quede amortizado por el volumen de inferencias posteriores.

En este sentido, las finanzas no son el único ámbito donde estas herramientas pueden tener un impacto muy significativo. Existen muchos otros campos, mucho más relevantes, como el desarrollo de fármacos, la química de materiales o el diseño de circuitos integrados, donde modelos físicos muy costosos de evaluar computacionalmente también se convierten en un cuello de botella potencialmente solucionable por medio de esta técnica.

No obstante, siempre se debe tener en cuenta que un surrogate es fiable únicamente dentro de la distribución de datos sobre la que se ha entrenado, y su extrapolación a regiones no muestreadas carece de garantías. En el fondo, la potencia de esta técnica reside en que traslada el cómputo desde el dominio de operaciones numéricas irregulares como la integración, inversión, búsqueda de raíces hacia el dominio del álgebra lineal, que es la forma de cálculo sobre la que se han concentrado los mayores avances en hardware y software de la última década. Un surrogate no sustituye necesariamente el cómputo por uno de menos operaciones, sino por uno para el cual los chips modernos (GPUs, TPUs, tensor cores) son extremadamente eficientes.

Referencias

- [1] J. M. Hutchinson, A. W. Lo y T. Poggio. A nonparametric approach to pricing and hedging derivative securities via learning networks. *Journal of Finance*, 49(3):851–889, 1994.
- [2] S. Becker, P. Cheridito y A. Jentzen. Deep optimal stopping. *Journal of Machine Learning Research*, 20:1–25, 2019.
- [3] J. Ruf y W. Wang. Neural networks for option pricing and hedging: a literature review. *Journal of Computational Finance*, 24(1):1–46, 2020.
- [4] H. Chen, A. Didisheim y S. Scheidegger. Deep surrogates for finance: with an application to option pricing. *Manuscript / SSRN preprint*, 2025.
- [5] B. Huge y A. Savine. Differential machine learning. *Risk Magazine* y SSRN, 2020.
- [6] J. Sirignano y K. Spiliopoulos. DGM: a deep learning algorithm for solving partial differential equations. *Journal of Computational Physics*, 375:1339–1364, 2018.
- [7] J. Han, A. Jentzen y W. E. Solving high-dimensional partial differential equations using deep learning. *Proceedings of the National Academy of Sciences*, 115(34):8505–8510, 2018.
- [8] R. Ferguson y A. Green. Deeply learning derivatives. *arXiv preprint arXiv:1809.02233*, 2018.

- [9] H. Buehler, L. Gonon, J. Teichmann y B. Wood. Deep hedging. *Quantitative Finance*, 19(8):1271–1291, 2019.
- [10] *Calibrating stochastic volatility models with differential machine learning. SSRN preprint*, 2023.
- [11] A. R. Barron. Universal approximation bounds for superpositions of a sigmoidal function. *IEEE Transactions on Information Theory*, 39(3):930–945, 1993.
- [12] P. Grohs, F. Hornung, A. Jentzen y P. von Wurstemberger. A proof that artificial neural networks overcome the curse of dimensionality in the numerical approximation of Black-Scholes partial differential equations. *arXiv preprint arXiv:1809.02362*, 2018.
- [13] L. N. Smith. Cyclical learning rates for training neural networks. *arXiv preprint arXiv:1506.01186*, 2015.
- [14] I. Loshchilov y F. Hutter. SGDR: Stochastic gradient descent with warm restarts. *arXiv preprint arXiv:1608.03983*, 2017.
- [15] R. Lord y C. Kahl. Optimal Fourier inversion in semi-analytical option pricing. *Journal of Computational Finance*, 10(4):1–30, 2007.